提出日: 2025 年 11 月 23 日

研究プロジェクト課題

学籍番号: 23B30575

氏名: 鳥光俊佑

Video Super-Resolution With Convolutional Neural Networks[1] のまとめ

鳥光 俊佑

2025 年 11 月 23 日

なんのための研究か

UHD テレビの普及に伴い, 低画質映像から高画質映像へ変換する超解像アルゴリズム (SR アルゴリズム) が求められている。

この研究は, CNN を映像の超解像へ応用し, 静止画での事前学習と時間的に連続するフレームの統合により, 従来より高速かつ高画質な超解像を実現する研究である。

従来のアプローチとその問題点

モデルベースのアプローチ

モデルベースのアプローチとして, 事前分布をもちいたベイズ推定に基づく手法が提案されている。

この手法は後述する CNN ベースの手法と比較して計算コストが高いという問題がある。

学習ベースのアプローチ

学習ベースのアプローチとして辞書学習に基づく手法が紹介されている。この手法では, 低解像度画像と高解像度画像のパッチペアから辞書を学習し, 辞書の元の線型結合として画像を再構成する。

この手法では, 画像の再構成もパッチごとに行うため, 計算コストが高いという問題がある。

単一画像に CNN を用いたアプローチ

単一画像の超解像に CNN を用いる手法 (SR CNN) も提案されている。CNN ベースの手法では, 画像を超解像する処理は順伝播しょりによって行われるため, ベイズのような方法と異なり反復計算を必要としない。

しかし, この手法では映像の時間次元の情報を活用できないという問題がある。

この論文でのアプローチ

この論文では, SR CNN を拡張し連続する複数のフレームを入力とする CNN(VSRnet) を提案している。

また, 隣接するフレーム間の影響によるフレーム間の位置のずれを削減する手法として Adaptive Motion Compensation(AMC) を提案している。

さらに, 静止画を使用してモデルを事前学習することで映像データが不足していても高精度な超解像を実現する手法についても述べている。

この論文で用いられるアプローチの新規性

VSRnet の新規性は以下の 3 点である。

- 従来の CNN ベースの手法は単一画像を対象としていたが, VSRnet では映像の時間的連続性を考慮するため連続する複数フレームを入力とする CNN を提案している。
- Motion Compensation について, 従来のオプティカルフローに基づく手法とは異なり隣接フレームの影響を考慮する AMC (Adaptive Motion Compensation) を提案している。
- 静止画上で SR アーキテクチャを事前学習し, その得られたパラメータで映像用 SR アーキテクチャの学習を初期化する手法を提案している。

この論文により出来るようになったこと

VSRnet は, 従来の最高制度である手法 (ベイズ推定, SR-CNN) を上回る PSNR, SSIM を達成していることが実験により確認された。

また, GPU のサポートによって, 従来のベイズ法の 66 倍ほどの高速化を実現した。

出力映像の視覚的品質についても, ベイズ推定による手法と比較してリンギングアーティファクトが少なく, 高精細な映像を生成できることが確認された。

鍵となる式や図

隣接フレームの結合方式の比較

論文中の Fig. 2 では, 映像用 SR アーキテクチャにおける連続時間のフレーム結合方式の比較が示されている。

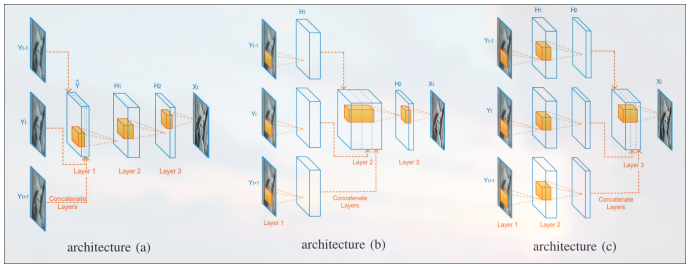

図 1　映像用 SR アーキテクチャにおけるフレームの結合方式の比較

映像用 SR アーキテクチャは 3 つの層からなり, 図 1 で示されている (a), (b), (c) のアーキテクチャはそれぞれ:

- (a) 入力層でフレームを結合
- (b) 中間層で各フレームを独立に処理した後, 結合する方式
- (c) 各フレームを独立に処理し, 最終層で結合する方式

となっている。どの方式の性能を似通ってはいるもの、実験により (b) の方式が最高の PNSR を達成することが確認されている。また, 論文中の Fig. 6 では図 2 のように (b) の方式が学習時間と性能のバランスで最も優れていることが示されている。

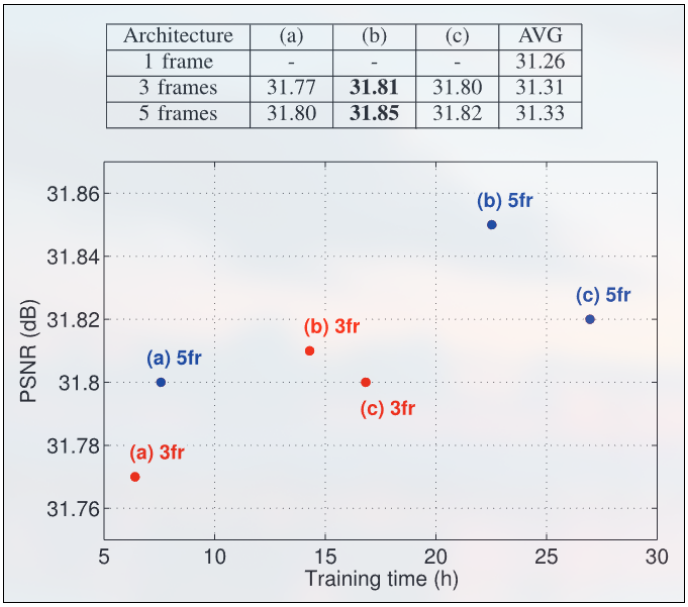

Architecture	(a)	(b)	(c)	AVG
1 frame	-	-	-	31.26
3 frames	31.77	**31.81**	31.80	31.31
5 frames	31.80	**31.85**	31.82	31.33

図 2　各方式の学習時間と PSNR

AMC の定義式

論文中の式 (6), (7) では AMC の定義が示されている。

$$y_{t-T}^{amc}(i,j) = (1 - r(i,j))y_t(i,j) + r(i,j)y_{t-T}^{MC}(i,j) \tag{6}$$

$$r(i,j) = \exp(-ke(i,j)) \tag{7}$$

各変数の意味は以下の通りである。

- $y_{t-T}^{amc}(i,j)$: AMC 後のフレーム $t-T$ の値
- $y_t(i,j)$: 現在のフレーム t の値
- $y_{t-T}^{MC}(i,j)$: Motion Compensation を行った後のフレーム $t-T$ の値
- $r(i,j)$: ピクセル (i,j) における重み（隣接フレームの信頼度と見做せる）
- $e(i,j)$: ピクセル (i,j) における Motion Compensation の誤差
- k: 定数

AMC の定義式から, $r(i,j)$ が小さいほど, 隣接フレームの信頼性が低いと判断され, 現在のフレームの値で埋めようとすることがわかる。

AMC がない場合は, 信頼度の低い隣接フレームの情報も使用してしまうため, 出力画像にアーティファクトが発生しやすくなる。AMC を用いることで, 隣接フレームの信頼性に応じて情報を取捨選択できるため, 高精度な超解像が可能になると考えられる。

事前学習させた重みの転移

事前学習モデルでは, 単一の画像を入力とするが, 映像用 SR アーキテクチャでは複数のフレームを入力とする。そのため, 入力チャネル数が異なる事前学習モデルの重みをそのまま利用することはできない。

論文中の式 (5) では, 重みを転移させる具体的な数式が示されている。

$$\begin{aligned} w_v(m,n,t-1,c) = w_v(m,n,t,c) = w_v(m,n,t+1,c) \\ = \frac{1}{3}w(m,n,t,c) \end{aligned} \tag{5}$$

各変数の意味は以下の通りである。

- $w_v(m,n,t,c)$: 映像用 SR アーキテクチャの重み
- $w(m,n,t,c)$: 事前学習モデルの重み

論文では, 以下の仮定を置いている: 映像用 SR アーキテクチャで 3 つの等価なフレームを入力とした場合, その出力は事前学習モデルに単一のフレームを入力した場合と同じになるべきである。

この仮定に基づき計算していくことで, 式 (5) のような重みの転移方法が導出される。

論文では, (a), (b), (c) の 3 つのアーキテクチャが提案されているが, フレーム結合のタイミングによって重みを拡張する層が異なることに注意が必要である。

参考文献

[1] Armin Kappeler et al. “Video Super-Resolution With Convolutional Neural Networks”. In: IEEE Transactions on Computational Imaging 2.2 (2016), pp. 109–122. DOI: 10.1109/TCI.2016.2532323.